

THÀNH ĐOÀN TP. HỒ CHÍ MINH ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH SỞ
KHOA HỌC VÀ CÔNG NGHỆ TP. HỒ CHÍ MINH

CÔNG TRÌNH DỰ THI
GIẢI THƯỞNG SINH VIÊN NGHIÊN CỨU KHOA HỌC EURÉKA
LẦN THỨ 28 NĂM 2026

SCAMGUARD-VN
NHẬN DIỆN DẤU HIỆU LỪA ĐẢO TRONG HỘI THOẠI TIẾNG VIỆT
BẰNG PHÂN TÍCH HÀNH ĐỘNG VÀ HỌC TỪ
CÁC CẶP DỮ LIỆU ĐỐI CHỨNG

LĨNH VỰC NGHIÊN CỨU: CÔNG NGHỆ THÔNG TIN
CHUYÊN NGÀNH: TRÍ TUỆ NHÂN TẠO

Mã số công trình: [BAN TỔ CHỨC GHI]

Thành phố Hồ Chí Minh, năm 2026

MỤC LỤC

MỤC LỤC	1
DANH MỤC BẢNG	2
DANH MỤC HÌNH	3
DANH MỤC TỪ VIẾT TẮT VÀ THUẬT NGỮ	3
TÓM TẮT CÔNG TRÌNH	4
1. ĐẶT VẤN ĐỀ	5
1.1. Bối cảnh và sự cần thiết	5
1.2. Ví dụ dẫn nhập	5
1.3. Bài toán nghiên cứu	6
1.4. Mục tiêu nghiên cứu	6
1.5. Phạm vi và giới hạn tuyên bố	7
2. TỔNG QUAN NGHIÊN CỨU	7
2.1. Mô hình ngôn ngữ tiền huấn luyện	7
2.2. Học dựa trên dấu hiệu bề mặt	7
2.3. Dữ liệu đối chứng và kiểm tra hành vi	8
2.4. Biểu diễn qua khái niệm trung gian	8
2.5. Khoảng trống và định vị đóng góp	8
3. ĐỐI TƯỢNG, DỮ LIỆU VÀ PHƯƠNG PHÁP NGHIÊN CỨU	8
3.1. Đối tượng nghiên cứu	8
3.2. Hệ thống CandidateAction	9
3.3. Các thuộc tính thể hiện vai trò của câu	10
3.4. Quy tắc mức rủi ro	10
3.5. Nguồn và cấu trúc dữ liệu	11
3.6. Quy trình xây dựng và kiểm soát dữ liệu	12
3.7. Cặp dữ liệu đối chứng tối thiểu	13
3.8. Kiến trúc và quy trình suy luận	14
3.9. Thiết lập huấn luyện	15
3.10. Quy trình kiểm thử độc lập	16

3.11. Chỉ số đánh giá	16
CHƯƠNG 4. KẾT QUẢ VÀ THẢO LUẬN	17
4.1. Kết quả nhận diện thuộc tính ngữ nghĩa trên tập DEV	17
4.2. Kết quả mô hình mức độ rủi ro trên tập DEV	18
4.3. Kết quả trên tập kiểm thử độc lập 200 mẫu.....	18
4.4. Phân tích theo nhóm dữ liệu	19
4.5. Trả lời các câu hỏi nghiên cứu	19
4.6. Tính mới và sáng tạo	20
4.7. Ứng dụng thử nghiệm.....	20
4.8. Hạn chế	21
CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	21
5.1. Kết luận.....	21
5.2. Đóng góp khoa học.....	22
5.3. Hướng phát triển.....	22
5.4. Khả năng tái lập	22
TÀI LIỆU THAM KHẢO	23
PHỤ LỤC	24
Phụ lục A. Lược đồ một mẫu dữ liệu ngữ nghĩa	24
Phụ lục B. Trạng thái hợp lệ của phép thử độc lập	24
Phụ lục C. Dấu vân tay SHA256 của các thành phần nghiên cứu	24
Phụ lục D. Luồng sử dụng ứng dụng.....	24
Phụ lục E. Gợi ý tái chạy	25

DANH MỤC BẢNG

Bảng 1. Ba câu có cùng từ khóa nhưng khác vai trò giao tiếp

Bảng 2. Hệ thống CandidateAction của ScamGuard-VN

Bảng 3. Bốn thuộc tính thể hiện vai trò của câu

Bảng 4. Quy tắc xác định mức rủi ro

Bảng 5. Thành phần và quy mô dữ liệu

Bảng 6. Ví dụ về cặp dữ liệu đối chứng tối thiểu

Bảng 7. Cấu hình huấn luyện chính

Bảng 8. Kết quả mô hình ngữ nghĩa trên tập DEV

Bảng 9. Kết quả mô hình mức độ rủi ro trên tập DEV

Bảng 10. Kết quả kiểm thử độc lập 200 trường hợp

Bảng 11. Ma trận nhầm lẫn trên bộ kiểm thử độc lập

Bảng 12. Hạn chế và hướng khắc phục

DANH MỤC HÌNH

Hình 1. Ba phát ngôn cùng nhắc đến OTP nhưng khác vai trò giao tiếp

Hình 2. Quy trình xây dựng và kiểm soát dữ liệu

Hình 3. Quy trình suy luận của ScamGuard-VN

Hình 4. Quy trình kiểm thử độc lập có đóng băng thành phần nghiên cứu

DANH MỤC TỪ VIẾT TẮT VÀ THUẬT NGỮ

Bảng thuật ngữ sử dụng trong công trình

Thuật ngữ	Giải thích
AI	Trí tuệ nhân tạo (Artificial Intelligence)
API	Giao diện lập trình ứng dụng (Application Programming Interface)
DEV	Tập phát triển dùng để chọn bản mô hình đã lưu và phân tích lỗi
Nhãn chuẩn nhãn	Nhãn chuẩn dùng để đối chiếu với kết quả dự đoán
Mẫu âm khó (mẫu âm khó)	Không nguy hiểm nhưng chứa dấu hiệu bề mặt giống lừa đảo
Macro-F1	Trung bình điểm F1 của từng lớp, mỗi lớp có trọng số như nhau
OCR	Nhận dạng ký tự quang học từ ảnh
QR	Mã phản hồi nhanh có thể chứa văn bản hoặc đường dẫn
SHA256	Thuật toán tạo dấu vân tay số để phát hiện tệp bị thay đổi
XLM-R	Mô hình ngôn ngữ đa ngữ XLM-RoBERTa

TÓM TẮT CÔNG TRÌNH

Lừa đảo qua tin nhắn và hội thoại trực tuyến thường thúc đẩy người nhận thực hiện một hành động có rủi ro, chẳng hạn chuyển tiền, cung cấp mã OTP, cài ứng dụng hoặc truy cập đường dẫn. Tuy nhiên, chính những từ ngữ này cũng xuất hiện trong cảnh báo an toàn, câu hỏi xác minh và lời thuật lại. Vì vậy, mô hình chỉ dựa vào từ khóa dễ cảnh báo sai câu như “không cung cấp OTP cho bất kỳ ai”, đồng thời có thể bỏ sót tình huống lừa đảo được diễn đạt gián tiếp.

ScamGuard-VN tiếp cận bài toán bằng cách phân tích hai lớp thông tin. Lớp thứ nhất xác định hành động đang được đề cập và bốn thuộc tính cho biết hành động đó có thực sự được yêu cầu, bị phủ định, được trích dẫn hay đang được thuật lại. Lớp thứ hai phân loại mức rủi ro thành chưa có bằng chứng rõ, cần xem xét và có bằng chứng nguy hiểm rõ. Mô hình sử dụng XLM-R làm bộ mã hóa chung, được huấn luyện bằng dữ liệu hội thoại tiếng Việt cùng các cặp dữ liệu đối chứng tối thiểu (counterfactual pairs). Mỗi cặp giữ gần nguyên nội dung và từ khóa nhưng thay đổi vai trò giao tiếp, qua đó buộc mô hình chú ý đến ý nghĩa của câu thay vì học máy móc từ một số từ nhạy cảm.

Dữ liệu ngữ nghĩa gồm 4.717 mẫu huấn luyện và 486 mẫu DEV; dữ liệu mức độ rủi ro gồm 3.805 mẫu huấn luyện và 398 mẫu DEV. Trên DEV, CandidateAction đạt Macro-F1 96,14%, Supported-action đạt 99,13% và mô hình mức độ rủi ro đạt Macro-F1 96,72%. Trên bộ kiểm thử độc lập 200 trường hợp chưa xuất hiện trong huấn luyện/DEV, độ chính xác nghiêm ngặt đạt 76,50%, Macro-F1 trên hai nhãn có nhãn chuẩn đạt 81,79% và độ chính xác vận hành đạt 86,50%. Trong 70 trường hợp dương, 90% được cảnh báo vàng hoặc đỏ. Kết quả độc lập thấp hơn DEV cho thấy hệ thống đã học được tín hiệu hữu ích nhưng vẫn chịu ảnh hưởng của sự khác biệt giữa dữ liệu huấn luyện và tình huống mới.

Đóng góp của công trình gồm: hệ thống biểu diễn hành động và vai trò câu cho miền lừa đảo tiếng Việt; phương pháp xây dựng dữ liệu đối chứng có kiểm soát; quy trình kiểm thử độc lập đóng băng bản mô hình đã lưu, đầu vào và kết quả dự đoán bằng SHA256; cùng ứng dụng Android nhận văn bản, ảnh và QR rồi gọi mô hình chạy cục bộ trên máy tính xách tay. Tầng sinh hướng dẫn là thành phần tùy chọn, hoạt động sau phân loại và không được phép thay đổi nhãn. Công trình được xác định là công cụ hỗ trợ cảnh báo, không thay thế việc xác minh qua cơ quan hoặc tổ chức có thẩm quyền.

Từ khóa: nhận diện dấu hiệu lừa đảo; hội thoại tiếng Việt; XLM-R; dữ liệu đối chứng; phân tích hành động; ứng dụng Android.


1. ĐẶT VẤN ĐỀ

1.1. Bối cảnh và sự cần thiết

Tin nhắn lừa đảo ngày càng giống giao tiếp thông thường. Kẻ gian có thể mạo danh ngân hàng, sàn thương mại điện tử, cơ quan công quyền, trường học, doanh nghiệp tuyển dụng hoặc người quen. Nội dung thường không tuyên bố trực tiếp “đây là lừa đảo”, mà tạo một tình huống có vẻ hợp lý rồi thúc đẩy người nhận thực hiện hành động. Dấu hiệu quan trọng do đó nằm ở mối quan hệ giữa ngữ cảnh, hành động được nhắc tới và cách người gửi yêu cầu hành động đó.

Phương pháp tìm từ khóa có ưu điểm đơn giản nhưng không đủ để xử lý sự khác biệt về vai trò câu. Từ “OTP” có thể xuất hiện trong yêu cầu cung cấp bí mật, trong cảnh báo không được tiết lộ hoặc trong lời kể về một sự việc đã xảy ra. Tương tự, một đường dẫn có thể là trang chính thức, đường dẫn giả mạo, ví dụ trong bài báo hoặc nội dung đang được người dùng hỏi để xác minh. Nếu mọi lần xuất hiện đều bị đánh dấu nguy hiểm, ứng dụng sẽ gây báo động giả; nếu bỏ qua từ khóa, hệ thống lại có nguy cơ bỏ sót yêu cầu nguy hiểm.

1.2. Ví dụ dẫn nhập



Hình 1. Ba phát ngôn cùng nhắc đến OTP nhưng khác vai trò giao tiếp

Bảng 1. Ba câu có cùng từ khóa nhưng khác vai trò giao tiếp

Phát ngôn	Hành động	Vai trò	Diễn giải
-----------	-----------	---------	-----------

Phát ngôn	Hành động	Vai trò	Diễn giải
Đọc mã OTP cho tôi.	Cung cấp bí mật	Yêu cầu trực tiếp	Có bằng chứng về hành động nhạy cảm đang được thúc đẩy.
Không đọc mã OTP cho bất kỳ ai.	Cung cấp bí mật	Bị phủ định	Đây là lời cảnh báo an toàn, không phải yêu cầu cung cấp OTP.
Họ từng bảo tôi đọc mã OTP.	Cung cấp bí mật	Thuật lại	Người nói đang kể lại sự việc; cần thêm ngữ cảnh để đánh giá tình huống hiện tại.

Ba câu trên có phần từ vựng rất giống nhau. Nếu mô hình chỉ học sự đồng xuất hiện giữa “OTP” và “đọc”, cả ba câu có thể bị đẩy về cùng một nhãn. ScamGuard-VN tách “hành động được đề cập” khỏi “hành động có thực sự được yêu cầu hay không”. Cách tách này cho phép hệ thống ghi nhận rằng cả ba câu đều liên quan đến cung cấp thông tin bí mật, nhưng chỉ câu thứ nhất là yêu cầu trực tiếp ở thời điểm quan sát.

1.3. Bài toán nghiên cứu

Đầu vào của hệ thống là một tin nhắn hoặc chuỗi lượt hội thoại tiếng Việt. Với mỗi đầu vào, hệ thống cần dự đoán CandidateAction, bốn thuộc tính trạng thái yêu cầu, trạng thái phủ định, trạng thái trích dẫn, trạng thái kể lại và mức độ rủi ro. CandidateAction là trường kỹ thuật biểu thị hành động được đề cập. Supported-action biểu thị hành động thực sự được yêu cầu: hành động phải khác NONE, được yêu cầu trực tiếp, không bị phủ định, không chỉ nằm trong trích dẫn và không chỉ được thuật lại.

Đầu ra mức độ rủi ro gồm ba mức. NO_EVIDENCE có nghĩa là chưa phát hiện bằng chứng nguy hiểm rõ trong nội dung đang quan sát. REVIEW biểu thị trường hợp chưa đủ chắc chắn và nên được xác minh qua kênh chính thức. HIGH_EVIDENCE biểu thị nội dung có bằng chứng rõ về hành động nhạy cảm đang được thúc đẩy. Ba mức này là mức hỗ trợ quyết định, không phải xác suất pháp lý rằng một cá nhân là kẻ lừa đảo.

1.4. Mục tiêu nghiên cứu

- Xây dựng hệ thống nhãn mô tả hành động và vai trò của câu trong hội thoại lừa đảo tiếng Việt.
- Huấn luyện mô hình có khả năng phân biệt yêu cầu thật với phủ định, trích dẫn và thuật lại.

- Giảm hiện tượng học dựa trên từ khóa bằng các cặp dữ liệu đối chứng tối thiểu và mẫu âm khó.
- Đánh giá mô hình bằng cả tập DEV và bộ kiểm thử độc lập có quy trình đóng băng, kiểm toán được.
- Triển khai bản thử nghiệm chứng minh tính khả thi gồm API cục bộ và ứng dụng Android nhận văn bản, ảnh hoặc QR.

1.5. Phạm vi và giới hạn tuyên bố

Công trình tập trung vào tiếng Việt dạng văn bản, gồm tin nhắn một chiều và hội thoại nhiều lượt. Ảnh và QR chỉ là kênh thu nhận: ảnh được chuyển thành văn bản bằng OCR, QR được giải mã thành chuỗi rồi mới đưa vào mô hình. Hệ thống chưa xác thực chủ sở hữu tên miền, danh tính người gửi, số điện thoại, tài khoản ngân hàng hoặc giao dịch thực tế. Vì vậy, kết quả chỉ phản ánh nội dung được cung cấp và phải được kết hợp với xác minh bên ngoài trong ứng dụng thực tế.

2. TỔNG QUAN NGHIÊN CỨU

2.1. Mô hình ngôn ngữ tiền huấn luyện

Transformer tạo nền tảng cho các mô hình ngôn ngữ hiện đại nhờ cơ chế chú ý (attention), cho phép mỗi từ tham chiếu đến các vị trí liên quan trong chuỗi [1]. BERT mở rộng khả năng học biểu diễn hai chiều và tinh chỉnh theo tác vụ [2]. XLM-R được tiền huấn luyện trên nhiều ngôn ngữ và có khả năng chuyển tri thức giữa các ngôn ngữ [3]. PhoBERT là mô hình tối ưu riêng cho tiếng Việt [4]. Công trình chọn XLM-R vì quy trình nghiên cứu ban đầu, bộ phân tách văn bản (tokenizer) và bản mô hình nền đã lưu (checkpoint) đã được xây dựng trên mô hình nền này; lựa chọn đó giúp kế thừa kết quả có sẵn và giữ khả năng xử lý biến thể đa ngữ, ký hiệu hoặc tên riêng trong tin nhắn.

2.2. Học dựa trên dấu hiệu bề mặt

Học lỗi tắt là hiện tượng mô hình dựa vào dấu hiệu dễ thấy nhưng không phản ánh bản chất của nhiệm vụ. Trong nhận diện lừa đảo, mô hình có thể gắn “OTP”, “chuyển khoản” hoặc “đường link” với nguy hiểm mà không xét ai đang nói, câu có phủ định hay không và hành động có thật sự được yêu cầu không. Cách học này có thể tạo kết quả tốt trên dữ liệu phát triển nếu huấn luyện và DEV có cùng kiểu diễn đạt, nhưng giảm mạnh khi gặp hội thoại mới.

2.3. Dữ liệu đối chứng và kiểm tra hành vi

Dữ liệu đối chứng (dữ liệu đối chứng) được tạo bằng cách thay đổi tối thiểu một mẫu để làm thay đổi nhãn hoặc thuộc tính mục tiêu [5]. Lợi ích chính không nằm ở việc tăng số lượng câu, mà ở khả năng chỉ ra yếu tố nào phải khiến mô hình thay đổi quyết định. Tuy nhiên, dữ liệu đối chứng có thể tạo thành phần nghiên cứu nếu hai phía khác nhau bởi một dấu hiệu máy móc hoặc mẫu câu lặp lại [6]. Vì vậy, công trình kiểm soát cặp theo tình huống, hành động và loại biến đổi; đồng thời đưa mẫu cùng cặp vào cùng một phân hoạch.

CheckList [8] là khung đánh giá hành vi của mô hình theo từng năng lực cụ thể, thay vì chỉ dựa vào một chỉ số tổng hợp. Tập đối sánh (contrast set) kiểm tra tính ổn định trước các biến đổi nhỏ nhưng có ý nghĩa [9]. ScamGuard-VN vận dụng tinh thần này bằng cách đo riêng CandidateAction, trạng thái yêu cầu, trạng thái phủ định, trạng thái trích dẫn, trạng thái kể lại, Supported-action và các nhóm có lừa đảo, mẫu âm khó, mẫu âm dễ trên tập độc lập.

2.4. Biểu diễn qua khái niệm trung gian

Mô hình nút thắt khái niệm dự đoán các khái niệm có ý nghĩa với con người trước hoặc cùng với nhãn cuối [7]. ScamGuard-VN kế thừa ý tưởng về khả năng quan sát đầu ra trung gian, nhưng không tuyên bố sử dụng một nút thắt khái niệm cứng. Mô hình mức độ rủi ro hiện tại kế thừa bộ mã hóa đã được huấn luyện ngữ nghĩa và sau đó tiếp tục tối ưu đầu cuối; mức độ rủi ro không bị buộc chỉ nhận năm điểm trước chuẩn hóa ngữ nghĩa làm đầu vào. Cách mô tả này phản ánh đúng kiến trúc đã cài đặt và tránh phóng đại mức độ can thiệp được của các khái niệm.

2.5. Khoảng trống và định vị đóng góp

Khoảng trống mà đề tài tập trung không phải là phát minh một mô hình nền mới. Đóng góp nằm ở việc kết hợp bốn thành phần cho tiếng Việt: hệ thống hành động và vai trò câu; dữ liệu đối chứng có kiểm soát; quy trình đánh giá độc lập có đóng băng thành phần nghiên cứu; và triển khai cục bộ trên Android. Trong phạm vi khảo sát, nhóm chưa tìm thấy công trình công khai cho tiếng Việt đồng thời mô tả đầy đủ bốn thành phần này. Nhận định này chỉ là kết quả khảo sát tài liệu hiện có, không phải tuyên bố tuyệt đối rằng chưa từng tồn tại nghiên cứu tương tự.

3. ĐỐI TƯỢNG, DỮ LIỆU VÀ PHƯƠNG PHÁP NGHIÊN CỨU

3.1. Đối tượng nghiên cứu

Đối tượng nghiên cứu là mối quan hệ giữa nội dung hội thoại, hành động được đề cập, vai trò giao tiếp của phát ngôn và mức rủi ro. Đơn vị đầu vào có thể là một tin

nhấn hoặc nhiều lượt hội thoại. Mỗi lượt gồm chỉ số thứ tự, vai người nói và văn bản. Lượt quan sát là lượt cuối cùng mà mô hình được phép sử dụng khi đưa ra kết quả dự đoán; các lượt sau, nếu có trong nguồn dữ liệu, không được cung cấp cho mô hình.

3.2. Hệ thống CandidateAction

CandidateAction là trường kỹ thuật chỉ loại hành động được đề cập trong câu hoặc hội thoại. Tên trường được giữ nguyên vì được sử dụng trực tiếp trong dữ liệu và mã nguồn; phần mô tả tiếng Việt giúp người đọc hiểu ý nghĩa vận hành của từng lớp.

Bảng 2. Hệ thống CandidateAction của ScamGuard-VN

Mã nhãn	Ý nghĩa	Ví dụ điển hình
NONE	Không xác định hành động thuộc hệ thống nhãn	Chào bạn; hôm nay trời mưa.
TRANSFER_VALUE	Chuyển tiền, nộp phí, đặt cọc hoặc chuyển tài sản	Chuyển trước 500 nghìn để giữ đơn.
DISCLOSE_SECRET	Cung cấp OTP, mật khẩu, PIN hoặc bí mật xác thực	Đọc mã OTP cho tôi để xác minh.
INSTALL_SOFTWARE	Cài ứng dụng, tệp APK hoặc phần mềm	Cài ứng dụng hỗ trợ từ đường dẫn này.
GRANT_DEVICE_ACCESS	Cấp quyền trợ năng, chia sẻ màn hình hoặc điều khiển từ xa	Bật quyền trợ năng để kỹ thuật viên kiểm tra.
MOVE_CONVERSATION	Chuyển sang kênh liên lạc khác	Nhấn qua Telegram để được hướng dẫn.
FOLLOW_LINK	Mở hoặc truy cập đường dẫn	Bấm vào đường dẫn để nhận quà.
SEND_MESSAGE	Gửi nội dung hoặc tin nhắn tới đối tượng khác	Soạn tin DK gửi đến số này.
PARTICIPATE_TASK	Thực hiện nhiệm vụ, chốt đơn, đánh giá hoặc thao tác tuần tự	Hoàn thành ba nhiệm vụ để rút hoa hồng.
SELECT_OPTION	Chọn nút, phương án hoặc lựa chọn được hướng dẫn	Nhấn phím 1 để xác nhận giao dịch.

Lớp NONE không có nghĩa là mô hình đã học được mọi hoạt động đời sống và chứng minh không có hành động nào. Nó chỉ có nghĩa là mô hình không chọn được một trong chín nhóm hành động đã định nghĩa. Đây là một lớp đóng, do đó hành động mới ngoài hệ thống phân loại có thể bị ép vào NONE hoặc một lớp gần nhất. Hạn chế

này được trình bày công khai và là lý do đề xuất nghiên cứu nhận diện hành động theo hướng tập mở trong tương lai.

3.3. Các thuộc tính thể hiện vai trò của câu

Bốn thuộc tính được gán độc lập theo giá trị YES hoặc NO. Chúng không thay thế CandidateAction mà bổ sung thông tin về cách hành động xuất hiện trong phát ngôn. Một câu có thể nhắc đúng hành động DISCLOSE_SECRET nhưng trạng thái yêu cầu bằng NO vì đang phủ định hoặc thuật lại.

Bảng 3. Bốn thuộc tính thể hiện vai trò của câu

Thuộc tính	Câu hỏi gán nhãn	Ví dụ YES	Trường hợp dễ nhầm
Trạng thái yêu cầu	Người gửi có yêu cầu người nhận thực hiện hành động không?	Gửi mã OTP cho tôi.	Câu hỏi về việc có cần OTP không chưa chắc là yêu cầu cung cấp.
Trạng thái phủ định	Hành động có nằm trong phạm vi phủ định không?	Không gửi mật khẩu cho ai.	Phủ định một chi tiết khác không nhất thiết phủ định hành động chính.
Trạng thái trích dẫn	Nội dung có chỉ nằm trong phần được trích dẫn không?	Tin nhắn ghi: “gửi OTP ngay”.	Dấu ngoặc kép không phải lúc nào cũng là trích dẫn độc lập.
Trạng thái kể lại	Người nói có đang thuật lại sự việc hoặc lời nói trước đó không?	Họ từng yêu cầu tôi chuyển tiền.	Thuật lại có thể đi cùng một yêu cầu mới ở lượt hiện tại.

Supported-action được tính là đúng khi CandidateAction khác NONE, trạng thái yêu cầu bằng YES và ba thuộc tính trạng thái phủ định, trạng thái trích dẫn, trạng thái kể lại đều bằng NO. Đây là quy tắc tổng hợp phục vụ phân tích, không phải một đầu ra được mã hóa cứng để quyết định mức độ rủi ro. Mô hình mức độ rủi ro vẫn học từ biểu diễn hội thoại đầu cuối, nhưng bộ mã hóa đã được huấn luyện bằng các nhiệm vụ ngữ nghĩa trước đó.

3.4. Quy tắc mức rủi ro

Bảng 4. Quy tắc xác định mức rủi ro

Mức	Ý nghĩa	Cách hiển thị	Hành động khuyến nghị
NO_EVIDENCE	Chưa phát hiện bằng chứng nguy hiểm rõ trong nội dung quan sát	Xanh	Tiếp tục thận trọng; vẫn bảo vệ dữ liệu nhạy cảm.

Mức	Ý nghĩa	Cách hiển thị	Hành động khuyến nghị
REVIEW	Thông tin chưa đủ rõ hoặc có tín hiệu cần xác minh	Vàng	Tạm dừng và kiểm tra qua ứng dụng, website hoặc số liên hệ chính thức.
HIGH_EVIDENCE	Có bằng chứng rõ về hành động nhạy cảm đang được thúc đẩy	Đỏ	Không thực hiện hành động; ưu tiên kết thúc liên hệ và báo cáo.

Tên mức được giữ nguyên trong dữ liệu để bảo đảm tương thích với mã nguồn. NO_EVIDENCE không đồng nghĩa “chắc chắn an toàn”, còn HIGH_EVIDENCE không phải phán quyết pháp lý. REVIEW là vùng hỗ trợ quyết định nhằm hấp thụ các trường hợp mô hình chưa chắc chắn hoặc nội dung cần thêm bằng chứng ngoài văn bản.

3.5. Nguồn và cấu trúc dữ liệu

Dữ liệu được hợp nhất từ nhiều đợt xây dựng, gồm mẫu do người viết, dữ liệu tổng hợp có kiểm soát, mẫu âm khó và các cặp đối chứng. Mỗi bản ghi chứa mã mẫu, chuỗi lượt hội thoại, lượt quan sát, nhãn ngữ nghĩa, nhãn mức độ rủi ro, nguồn gốc, mã nhóm tình huống và trạng thái đủ điều kiện đưa vào phân hoạch. Những trường nguồn gốc được dùng để kiểm tra dữ liệu nhưng không được đưa vào đầu vào mô hình khi suy luận.


Bảng 5. Thành phần và quy mô dữ liệu

Tác vụ	Huấn luyện	DEV	Vai trò
Ngữ nghĩa	4.717	486	Huấn luyện CandidateAction và bốn thuộc tính vai trò câu
Mức độ rủi ro	3.805	398	Huấn luyện ba mức NO_EVIDENCE, REVIEW, HIGH_EVIDENCE
Independent kiểm thử	0	0	200 Trường hợp khóa riêng, không thuộc huấn luyện/DEV

Đợt bổ sung giá trị cao sinh 204 mẫu đa chủ đề bằng mô hình ngôn ngữ. Kiểm tra tự động loại một mẫu vì trạng thái yêu cầu xung đột với trạng thái trích dẫn hoặc trạng thái kể lại, giữ 203 mẫu chỉ cho huấn luyện. Các mẫu này được đánh dấu

AI_GENERATED_REQUIRES_HUMAN_REVIEW, không được gọi là nhãn chuẩn do con người gán. Cách đánh dấu giúp tách rõ dữ liệu hỗ trợ huấn luyện khỏi dữ liệu dùng để tuyên bố độ chính xác.

3.6. Quy trình xây dựng và kiểm soát dữ liệu



Hình 2. Quy trình xây dựng và kiểm soát dữ liệu

Bước 1 - Thu thập và tổng hợp: Nội dung được đưa về một schema thống nhất. Những nguồn chưa rõ quyền sử dụng, dữ liệu có thông tin nhạy cảm hoặc bản ghi không xác định được ngữ cảnh bị loại khỏi tập công bố.

Bước 2 - Chuẩn hóa hội thoại: Văn bản được chuẩn hóa mã hóa ký tự và tổ chức thành các lượt. Mỗi lượt có speaker_role là USER, OTHER_PARTY hoặc SYSTEM. Không sửa lỗi chính tả theo cách làm mất dấu hiệu tự nhiên của tin nhắn.

Bước 3 - Gán nhãn ngữ nghĩa và mức độ rủi ro: Người xây dựng dữ liệu xác định hành động, bốn thuộc tính và mức rủi ro dựa trên nội dung tại lượt quan sát. Các quy tắc ưu tiên vai trò câu thay vì sự có mặt của từ khóa.

Bước 4 - Tạo dữ liệu đối chứng: Từ một mẫu nền, một thuộc tính được thay đổi bằng chỉnh sửa tối thiểu. Hành động và phần lớn từ vựng được giữ nguyên để tạo phép kiểm tra có chủ đích.

Bước 5 - kiểm tra: Chương trình kiểm tra mã nhãn, thứ tự lượt, xung đột logic, trùng lặp nguyên văn, pair_id thiếu đối tác và chồng lấn giữa các phân hoạch. Mẫu lỗi được sửa hoặc loại trước khi huấn luyện.

Bước 6 - Chia theo nhóm: Các mẫu cùng tình huống, cùng nguồn biến thể hoặc cùng cặp được giữ trong một phân hoạch. Quy tắc này giảm nguy cơ một câu gần giống nằm trong huấn luyện còn câu đối chứng nằm trong DEV.

3.7. Cặp dữ liệu đối chứng tối thiểu


Bảng 6. Ví dụ về cặp dữ liệu đối chứng tối thiểu

Mã u	Nội dung	Trạng thái yêu cầu	Trạng thái phủ định	Ý nghĩa
A	Gửi mã OTP cho tôi.	YES	NO	Yêu cầu cung cấp bí mật
B	Không gửi mã OTP cho bất kỳ ai.	NO	YES	Cảnh báo an toàn
C	Bấm đường dẫn để xác minh tài khoản.	YES	NO	Yêu cầu truy cập đường dẫn
D	Đừng bấm đường dẫn lạ để xác minh tài khoản.	NO	YES	Phủ định hành động

Cặp A-B giữ hành động DISCLOSE_SECRET và từ khóa OTP nhưng thay đổi phạm vi phủ định. Cặp C-D giữ hành động FOLLOW_LINK và ý định xác minh nhưng đổi từ yêu cầu sang cảnh báo. Hàm mất mát theo cặp là thành phần hàm mất mát sử dụng quan hệ giữa hai mẫu; ở phiên bản hiện tại, nó khuyến khích điểm trạng thái yêu cầu của mẫu yêu cầu cao hơn mẫu không yêu cầu một khoảng tối thiểu. Công trình không tuyên bố rằng toàn bộ quan hệ mức độ rủi ro giữa mọi loại cặp đã được đưa trực tiếp vào hàm mất mát.

Khác biệt trong cặp phải xuất phát từ ý nghĩa giao tiếp. Việc thêm “mã tham chiếu”, đổi tên người hoặc thay số tiền mà không thay đổi ý nghĩa chỉ tạo khác biệt giả và không giúp kiểm tra năng lực mong muốn. Vì vậy, các trường phụ không liên quan bị loại khỏi tiêu chí tạo cặp.

3.8. Kiến trúc và quy trình suy luận



Hình 3. Quy trình suy luận của ScamGuard-VN

Tiếp nhận đầu vào: Người dùng có thể nhập văn bản, chọn ảnh hoặc quét QR. OCR và bộ đọc QR chỉ chuyển dữ liệu sang chuỗi ký tự; chúng không tự quyết định mức độ rủi ro.

Tạo hội thoại quan sát được: Văn bản một chiều được xem là một lượt từ OTHER_PARTY. Hội thoại có nhãn vai người nói được giữ theo thứ tự; mô hình chỉ nhận các lượt đến observable_turn.

Mã hóa bằng XLM-R: Bộ phân tách văn bản chia chuỗi thành các đơn vị văn bản nhỏ. Bộ mã hóa tạo biểu diễn cho toàn bộ phần hội thoại và riêng lượt hiện tại, sau đó hai biểu diễn được nối lại.

Dự đoán ngữ nghĩa: Năm đầu ra dự đoán CandidateAction, trạng thái yêu cầu, trạng thái phủ định, trạng thái trích dẫn và trạng thái kể lại. Các xác suất này được trả về để phục vụ phân tích và giải thích kỹ thuật.

Phân loại mức độ rủi ro: Mô hình phân loại mức độ rủi ro sử dụng bộ mã hóa đã được huấn luyện ngữ nghĩa, đóng băng phần nhúng và sáu tầng đầu, rồi tối ưu bộ phân loại ba lớp. Nó học từ biểu diễn hội thoại chứ không dùng luật từ khóa.

Trả kết quả: API trả nhãn, độ tin cậy, điểm từng lớp và các thuộc tính ngữ nghĩa. Android ánh xạ NO_EVIDENCE, REVIEW, HIGH_EVIDENCE thành xanh, vàng, đỏ.

Sinh hướng dẫn tùy chọn: Nếu người dùng cấu hình Ollama Cloud, máy chủ gửi mức độ rủi ro, hành động và đoạn hội thoại tới mô hình sinh để tạo hướng xử lý và chế độ phản hồi. Tầng này không được đổi kết quả dự đoán của bộ phân loại.

3.9. Thiết lập huấn luyện

Bảng 7. Cấu hình huấn luyện chính


Thành phần	Thiết lập	Lý do
Mô hình nền	XLM-R base	Kế thừa quy trình và bản mô hình đã lưu nghiên cứu trước; phù hợp văn bản đa dạng ký hiệu.
Bộ tối ưu	AdamW; tốc độ học $1,5 \times 10^{-5}$; suy giảm trọng số 0,01	Tinh chỉnh ổn định ở tốc độ học nhỏ.
Lô dữ liệu	Lô dữ liệu 2; gradient accumulation 8	Phù hợp bộ nhớ RTX 4050 máy tính xách tay GPU.
Vòng huấn luyện	3	Theo dõi DEV sau mỗi vòng huấn luyện và chọn bản mô hình đã lưu tốt nhất.
Độ chính xác số	Bfloat16 trên CUDA	Giảm bộ nhớ và tăng tốc huấn luyện.
Phản đóng băng	Lớp biểu diễn đầu vào và sáu tầng bộ mã hóa đầu	Giữ biểu diễn nền, tập trung thích nghi các tầng trên.
Hạt giống ngẫu nhiên	40417 Cho ngữ nghĩa; 11019 cho rủi ro	Giảm dao động do xáo trộn và khởi tạo ngẫu nhiên.

Giai đoạn thứ nhất huấn luyện mô hình ngữ nghĩa. Hàm mất mát gồm entropy chéo của CandidateAction, bốn thuộc tính và hàm mất mát theo cặp. Trạng thái yêu cầu được đặt trọng số cao hơn vì đây là ranh giới quan trọng giữa việc chỉ nhắc tới hành động và thật sự thúc đẩy hành động. Bản mô hình đã lưu được chọn theo tổng có trọng số của Macro-F1 CandidateAction, Macro-F1 trạng thái yêu cầu và Macro-F1 Supported-action.

Giai đoạn thứ hai xây dựng mô hình phân loại mức độ rủi ro. Bộ mã hóa được nạp từ bản mô hình ngữ nghĩa đã lưu đã chọn; bộ phân loại mức độ rủi ro được khởi tạo mới. Phần nhúng và sáu tầng đầu được đóng băng, các tầng trên cùng bộ phân loại được tối ưu trên dữ liệu mức độ rủi ro. Cách chuyển bộ mã hóa này cung cấp sự giám sát ngữ nghĩa gián tiếp cho mức độ rủi ro, nhưng không biến hệ thống thành kiến trúc mà nhãn mức độ rủi ro chỉ phụ thuộc vào năm điểm dự đoán ngữ nghĩa.

3.10. Quy trình kiểm thử độc lập

QUY TRÌNH KIỂM THỬ ĐỘC LẬP



Nếu thay đổi mô hình, ngưỡng, dữ liệu hoặc dự đoán sau khi xem nhãn chuẩn thì phép thử mất hiệu lực.

Hình 4. Quy trình kiểm thử độc lập có đóng băng thành phần nghiên cứu

Khóa trước khi suy luận: Chốt bản mô hình ngữ nghĩa đã lưu, bản mô hình mức độ rủi ro đã lưu, quy trình tiền xử lý, bộ phân tách văn bản, thứ tự mẫu, quy tắc argmax và chính sách vận hành. Không được xem INTERNAL_GOLD.

Tách đầu vào và nhãn chuẩn: FINAL_MODEL_INPUT chỉ chứa nội dung mô hình được phép đọc. INTERNAL_GOLD chứa nhãn chuẩn và nhóm con, được giữ riêng đến khi kết quả dự đoán đã đóng băng.

Suy luận một lượt: Mô hình chạy đủ 200 mẫu, không chỉnh câu, không thay mô hình và không thử lại mẫu vì kết quả có vẻ sai.

Đóng băng kết quả dự đoán: Kết quả được lưu vào predictions_frozen.jsonl. Sau khi tệp tồn tại, chương trình suy luận từ chối ghi đè để tránh vô tình tạo lần chạy mới.

Tính SHA256: SHA256 tạo dấu vân tay số cho tệp. Chỉ cần thay một byte, mã kiểm tra sẽ khác, nhờ đó có thể phát hiện đầu vào hoặc kết quả dự đoán bị thay đổi.

Mở nhãn chuẩn và đánh giá: Nhãn chuẩn chỉ được mở sau khi kết quả dự đoán đã có mã băm. Chỉ số được tính đúng một lần. Nếu bất kỳ điều kiện nào bị vi phạm, phép thử phải ghi FINAL_INDEPENDENT_TEST_VALID=NO.

3.11. Chỉ số đánh giá

Accuracy là tỷ lệ kết quả dự đoán trùng nhãn chuẩn. Precision cho biết trong các mẫu mô hình dự đoán vào một lớp, bao nhiêu mẫu đúng. Recall cho biết trong các mẫu thật sự thuộc lớp đó, mô hình phát hiện được bao nhiêu. F1 là trung bình điều hòa giữa Precision và Recall. Macro-F1 tính F1 riêng cho từng lớp rồi lấy trung bình, vì vậy lớp ít mẫu không bị che lấp bởi lớp đông mẫu. Độ tin cậy trong ứng dụng là điểm softmax

của mô hình trên dữ liệu phát triển; nó chưa được xem là xác suất lừa đảo đã hiệu chỉnh ngoài thực tế.

Độ chính xác vận hành (độ chính xác vận hành) được định nghĩa trước khi đánh giá để phản ánh vai trò hỗ trợ ba mức: mẫu có lừa đảo được chấp nhận nếu kết quả dự đoán là REVIEW hoặc HIGH_EVIDENCE; mẫu âm khó được chấp nhận nếu là NO_EVIDENCE hoặc REVIEW; mẫu âm dễ yêu cầu NO_EVIDENCE. Chỉ số này luôn được trình bày cùng độ chính xác nghiêm ngặt (độ chính xác nghiêm ngặt), không được dùng để thay thế kết quả nghiêm ngặt.

CHƯƠNG 4. KẾT QUẢ VÀ THẢO LUẬN

4.1. Kết quả nhận diện thuộc tính ngữ nghĩa trên tập DEV

Bảng 8. Kết quả của mô hình ngữ nghĩa trên tập DEV

Nhiệm vụ	Accuracy (%)	Macro-F1 (%)
CandidateAction	96,30	96,14
Trạng thái yêu cầu	99,79	99,78
Trạng thái phủ định	99,79	99,34
Trạng thái trích dẫn	99,38	98,07
Trạng thái kể lại	98,56	97,23
Supported-action	99,18	99,13

Kết quả cho thấy mô hình học tốt các ranh giới ngữ nghĩa trong dữ liệu phát triển. Đặc biệt, trạng thái yêu cầu đạt Macro-F1 99,78%, phù hợp với mục tiêu giảm lỗi do thấy từ khóa rồi kết luận có yêu cầu. Supported-action đạt 99,13%, cho thấy việc kết hợp hành động với trạng thái được yêu cầu tạo ra một đại lượng gần hơn với ý nghĩa vận hành so với CandidateAction đơn lẻ.

Các con số trên không được hiểu là hiệu quả ngoài thực tế. Tập DEV được tách từ cùng quy trình xây dựng dữ liệu với tập huấn luyện nên có mức tương đồng về cách viết, độ sạch và phân bố. Vì vậy, nghiên cứu dùng thêm tập kiểm thử độc lập có nhiều câu tự nhiên, lỗi gõ và ngữ cảnh ngầm để đánh giá khả năng khái quát.

4.2. Kết quả mô hình mức độ rủi ro trên tập DEV

Bảng 9. Kết quả phân loại mức độ rủi ro trên tập DEV

Chỉ số	Kết quả (%)	Ý nghĩa
Accuracy	96,73	Tỷ lệ dự đoán đúng trên toàn bộ tập DEV.
Macro-F1	96,72	Trung bình F1 của ba lớp, không để lớp đông lấn át.

Mô hình mức độ rủi ro đạt kết quả cân bằng giữa các lớp trên DEV. Tuy nhiên, đây vẫn là kết quả trong miền dữ liệu phát triển. Độ tin cậy hiển thị trong ứng dụng là softmax của mô hình, chưa qua hiệu chỉnh xác suất trên một quần thể người dùng đại diện, nên báo cáo và giao diện đều phải chú thích rõ giới hạn này.

4.3. Kết quả trên tập kiểm thử độc lập 200 mẫu

Bảng 10. Kết quả chính của phép kiểm thử độc lập

Chỉ số	Kết quả	Cách diễn giải đúng
Độ chính xác nghiêm ngặt	76,50%	Đúng khi kết quả dự đoán trùng hoàn toàn nhãn chuẩn.
Macro-F1 trên các nhãn có trong nhãn chuẩn	81,79%	Trung bình F1 của NO_EVIDENCE và HIGH_EVIDENCE.
Weighted-F1	81,82%	F1 có trọng số theo số mẫu của từng nhãn.
Độ chính xác vận hành	86,50%	Chấp nhận vùng REVIEW theo quy tắc vận hành đã khóa trước.
Mẫu có lừa đảo được cảnh báo vàng/đỏ	$63/70 = 90,00\%$	Khả năng đưa tình huống dương vào vùng cần chú ý.
Mẫu âm khó không bị báo đỏ	$52/65 = 80,00\%$	Khả năng tránh cảnh báo quá mạnh cho phủ định khó.
Mẫu âm dễ được báo xanh	$58/65 = 89,23\%$	Khả năng nhận đúng nội dung thông thường.

Tập kiểm thử gồm 70 mẫu có lừa đảo, 65 mẫu âm khó và 65 mẫu âm dễ. Nhãn chuẩn chỉ có hai nhãn đích NO_EVIDENCE và HIGH_EVIDENCE; REVIEW là vùng đầu ra thận trọng của hệ thống chứ không phải một loại dữ liệu bị bỏ sót. Do đó, Macro-F1 tính cả ba lớp sẽ bằng 54,53% vì lớp REVIEW không có mẫu nhãn chuẩn;

báo cáo không dùng con số này làm kết luận chính nhưng vẫn công bố để bảo đảm minh bạch.

Khoảng cách giữa độ chính xác nghiêm ngặt 76,50% và độ chính xác vận hành 86,50% phản ánh đúng thiết kế ứng dụng hỗ trợ. Một số mẫu không đủ chắc để kết luận xanh hoặc đỏ được đưa vào REVIEW. Đây là hành vi có chủ đích, nhưng không được phép gọi độ chính xác vận hành là Accuracy của bài toán phân lớp thông thường.

4.4. Phân tích theo nhóm dữ liệu

Bảng 11. Phân tích kết quả theo ba nhóm kiểm thử

Nhóm	Số mẫu	Tiêu chí vận hành	Đạt	Tỷ lệ
Mẫu có lừa đảo	70	REVIEW hoặc HIGH_EVIDENCE	63	90,00%
Mẫu âm khó	65	NO_EVIDENCE hoặc REVIEW	52	80,00%
Mẫu âm dễ	65	NO_EVIDENCE	58	89,23%

Nhóm có lừa đảo đạt tỷ lệ cảnh báo cao nhất. Những trường hợp còn bỏ sót thường biểu đạt rủi ro gián tiếp, thiếu vai người nói, dùng tên miền giả nhưng không có động từ yêu cầu rõ, hoặc chỉ hé lộ một phần chuỗi thao tác. Điều này cho thấy mô hình vẫn phụ thuộc đáng kể vào dấu hiệu hành động trong văn bản.

Mẫu âm khó là nhóm khó nhất. Các câu như “không cung cấp OTP”, câu trích dẫn lời kẻ gian hoặc lời kẻ lại có nhiều từ nhạy cảm giống lừa đảo thật. Mô hình ngữ nghĩa giúp giảm nhầm lẫn, nhưng sai số vẫn xuất hiện khi phủ định ở xa hành động, cấu trúc hội thoại không rõ chủ thể hoặc nhiều ý trái chiều nằm trong cùng một đoạn.

Mẫu âm dễ đạt 89,23% xanh. Phần còn lại chủ yếu bị đẩy sang REVIEW do câu quá ngắn, chứa liên kết hoặc thực thể tài chính nhưng không đủ ngữ cảnh. Với ứng dụng hỗ trợ an toàn, REVIEW ở các trường hợp mơ hồ chấp nhận được hơn báo đỏ; tuy nhiên tỷ lệ này cũng chỉ ra nhu cầu hiệu chỉnh độ tin cậy và bổ sung dữ liệu đời sống đa dạng.

4.5. Trả lời các câu hỏi nghiên cứu

Đối với câu hỏi thứ nhất, kết quả trạng thái yêu cầu và Supported-action trên DEV cho thấy phân tích thuộc tính ngữ nghĩa có khả năng học được khác biệt giữa “nhắc đến” và “thực sự yêu cầu”. Các cặp đối chứng góp phần làm ranh giới này rõ

hơn, dù nghiên cứu hiện chưa có thí nghiệm loại bỏ thành phần trên cùng một tập kiểm thử để định lượng riêng mức đóng góp.

Đối với câu hỏi thứ hai, phép thử độc lập xác nhận mô hình giảm nhiễu cảnh báo sai nghiêm trọng ở mẫu âm khó: 80% mẫu không bị xếp đỏ. Tuy vậy, độ chính xác nghiêm ngặt 76,50% cho thấy khả năng khái quát chưa đạt mức triển khai như một công cụ phán quyết tự động.

Đối với câu hỏi thứ ba, cơ chế ba mức giúp giữ 90% mẫu có lừa đảo trong vùng vàng hoặc đỏ đồng thời giữ 89,23% mẫu âm dễ ở xanh. Kết quả 86,50% chỉ có ý nghĩa theo chính sách vận hành đã công bố, không thay thế chỉ số phân lớp nghiêm ngặt.

4.6. Tính mới và sáng tạo

Tính mới của công trình không nằm ở việc phát minh XLM-R, mà ở cách tổ chức bài toán tiếng Việt theo hành động và quan hệ ngữ nghĩa. Thay vì học trực tiếp từ vài từ nhạy cảm tới nhãn lừa đảo, hệ thống buộc mô hình đồng thời dự đoán hành động, yêu cầu, phủ định, trích dẫn và kể lại. Cách biểu diễn này tạo một lớp giải thích trung gian có thể kiểm tra.

Đóng góp thứ hai là dữ liệu đối chứng theo cặp: hai câu gần nhau về từ vựng nhưng khác ở một quan hệ quyết định. Điều này hướng mô hình tới sự thay đổi ý nghĩa nhỏ, ví dụ “hãy gửi OTP” so với “không gửi OTP”, thay vì ghi nhớ chủ đề.

Đóng góp thứ ba là quy trình kiểm thử có khóa thành phần nghiên cứu và SHA256. Kết quả dự đoán được đóng băng trước khi mở nhãn chuẩn, giúp phân biệt phép thử độc lập với việc đánh giá lại sau khi đã xem kết quả. Đây là đóng góp về tính kiểm chứng của quy trình nghiên cứu, đặc biệt cần thiết với mô hình được cải tiến lặp lại.

4.7. Ứng dụng thử nghiệm

Ứng dụng Android nhận ba loại đầu vào: văn bản dán trực tiếp, ảnh chụp màn hình được OCR và mã QR. Nội dung được gửi tới máy chủ cục bộ chạy trên máy tính có bản mô hình đã lưu. Máy chủ trả về mức độ, độ tin cậy và dữ liệu kỹ thuật; ứng dụng chỉ trình bày kết quả, không tự gán nhãn bằng danh sách từ khóa.

Sau bước phân loại, một mô hình ngôn ngữ tùy chọn có thể sinh hai trường: hướng dẫn xử lý và phương án phản hồi. Thành phần này nhận cả nội dung người dùng và mức độ do bộ phân loại trả về, nhưng không được phép sửa mức độ rủi ro. Nếu dịch vụ sinh phản hồi không khả dụng, chức năng phân loại cốt lõi vẫn hoạt động.

4.8. Hạn chế

Bảng 12. Hạn chế và ảnh hưởng tới kết luận

Hạn chế	Ảnh hưởng	Hướng khắc phục
Dữ liệu huấn luyện có tỷ lệ tổng hợp đáng kể	Ngôn ngữ có thể sạch và rõ hơn hội thoại thật.	Thu thập dữ liệu thực đã ẩn danh và đánh giá chéo bởi con người.
Nhãn chuẩn độc lập không có lớp REVIEW	Không thể ước lượng trực tiếp F1 của vùng mơ hồ.	Tạo tập ba lớp với tiêu chí gán REVIEW rõ và nhiều người gán nhãn.
Chưa có thí nghiệm loại bỏ thành phần trên cùng kiểm thử	Chưa định lượng riêng đóng góp của từng đầu dự đoán và hàm mất mát theo cặp.	Huấn luyện các cấu hình bỏ từng thành phần, giữ nguyên hạt giống ngẫu nhiên và tập kiểm thử.
Độ tin cậy chưa hiệu chỉnh	Không được diễn giải là xác suất lừa đảo thực tế.	Hiệu chỉnh trên tập đại diện và đo Expected Calibration Error.
Mới tập trung tiếng Việt dạng văn bản	Chưa bao quát âm thanh, hình ảnh hoặc hành vi ngoài văn bản.	Mở rộng đa phương thức trong nghiên cứu tiếp theo.
Ứng dụng phụ thuộc máy chủ cục bộ	Khó sử dụng khi máy tính xách tay và điện thoại không cùng mạng.	Nghiên cứu lượng tử hóa hoặc triển khai máy chủ có cơ chế bảo vệ dữ liệu.

Vì các hạn chế trên, ScamGuard-VN được định vị là công cụ hỗ trợ cảnh báo. Người dùng vẫn cần xác minh qua ứng dụng, website hoặc số liên hệ chính thức; hệ thống không thay thế cơ quan chức năng, chuyên gia an toàn thông tin hoặc quyết định của con người.

CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1. Kết luận

Công trình đã xây dựng một hệ thống thử nghiệm nhận diện dấu hiệu lừa đảo trong hội thoại tiếng Việt theo hướng phân tích hành động và quan hệ ngữ nghĩa. Hệ thống không chỉ dự đoán mức độ rủi ro mà còn nhận diện hành động được đề cập và bốn trạng thái trạng thái yêu cầu, trạng thái phủ định, trạng thái trích dẫn, trạng thái kể lại. Cấu trúc này giải quyết trực tiếp hiện tượng cùng một từ nhạy cảm có thể xuất hiện trong yêu cầu lừa đảo, lời cảnh báo, câu phủ định hoặc lời kể lại.

Trên tập DEV, mô hình ngữ nghĩa đạt Macro-F1 96,14% cho CandidateAction và 99,13% cho Supported-action; mô hình mức độ rủi ro đạt Accuracy 96,73% và Macro-F1 96,72%. Trên 200 mẫu kiểm thử độc lập khó hơn, độ chính xác nghiêm ngặt đạt 76,50%, Macro-F1 trên hai nhãn có trong nhãn chuẩn đạt 81,79% và độ chính xác vận

hành đạt 86,50%. Sự chênh lệch giữa DEV và kiểm thử độc lập được công bố như một bằng chứng về dịch chuyển miền và giới hạn khái quát, không bị che bằng chỉ số thuận lợi hơn.

5.2. Đóng góp khoa học

- Đề xuất cách biểu diễn bài toán nhận diện lừa đảo tiếng Việt bằng CandidateAction và các thuộc tính ngữ nghĩa, tạo lớp thông tin trung gian có thể kiểm tra.
- Xây dựng dữ liệu đối chứng theo cặp để mô hình học sự thay đổi ý nghĩa do yêu cầu, phủ định, trích dẫn và kể lại, thay vì chỉ học từ khóa hoặc chủ đề.
- Thiết kế mô hình hai giai đoạn, chuyển bộ mã hóa đã học ngữ nghĩa sang bài toán rủi ro và giữ ba mức đầu ra phù hợp với vai trò hỗ trợ.
- Thực hiện quy trình kiểm thử độc lập có đóng băng đầu vào, bản mô hình đã lưu, kết quả dự đoán và SHA256 trước khi mở nhãn chuẩn, qua đó tăng khả năng tái kiểm chứng.
- Xây dựng nguyên mẫu Android hỗ trợ văn bản, ảnh chụp màn hình và QR, kết nối với mô hình chạy cục bộ để hạn chế phải chuyển nội dung nhạy cảm tới dịch vụ phân loại bên ngoài.

5.3. Hướng phát triển

Nghiên cứu tiếp theo sẽ ưu tiên dữ liệu thật đã ẩn danh, có nhiều người gán nhãn và đo mức đồng thuận. Tập kiểm thử mới cần có đủ ba lớp, đặc biệt các trường hợp REVIEW thật sự mơ hồ, đồng thời phải được giữ kín cho đến khi bản mô hình đã lưu và ngưỡng đã khóa.

Về mô hình, nhóm dự kiến thực hiện thí nghiệm loại bỏ từng thành phần, huấn luyện đối chứng cùng hạt giống ngẫu nhiên và đánh giá trên cùng giao thức để đo chính xác đóng góp của mỗi đầu dự đoán ngữ nghĩa và hàm mất mát theo cặp. Quan hệ giữa véc-tơ ngữ nghĩa và mức độ rủi ro cũng sẽ được ràng buộc rõ hơn bằng mục tiêu nhất quán, thay vì chỉ chuyển bộ mã hóa.

Về triển khai, các hướng chính gồm hiệu chỉnh độ tin cậy, tối ưu tốc độ, lượng tử hóa để chạy trực tiếp trên thiết bị, bảo vệ nội dung OCR và đánh giá với người dùng. Phần sinh hướng dẫn cần có bộ tiêu chí an toàn riêng, kiểm soát khả năng bịa thông tin và luôn tách khỏi quyết định phân loại cốt lõi.

5.4. Khả năng tái lập

Mã nguồn, cấu trúc dữ liệu, chương trình huấn luyện, đánh giá và hướng dẫn chạy được công bố tại: <https://github.com/TuanAnhPhan-pika/SCAMGUARD-VN>

Kho lưu trữ cung cấp bản mô hình đã lưu ngữ nghĩa và mức độ rủi ro qua bản phát hành, tệp kê khai SHA256, cấu hình môi trường và lệnh chạy máy chủ. Việc tái chạy có thể có sai khác nhỏ do phiên bản thư viện, phần cứng và phép toán GPU; các mã băm được dùng để xác nhận đúng thành phần nghiên cứu của kết quả đã báo cáo.

TÀI LIỆU THAM KHẢO

- [1] T. Conneau và cộng sự, “Unsupervised Cross-lingual Representation Learning at Scale,” *Proceedings of ACL*, 2020.
- [2] J. Devlin và cộng sự, “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding,” *Proceedings of NAACL-HLT*, 2019.
- [3] Y. Liu và cộng sự, “RoBERTa: A Robustly Optimized BERT Pretraining Approach,” *arXiv:1907.11692*, 2019.
- [4] J. Lin, G. Tremblay-Taylor, G. Mou, D. You và K. Lee, “Detecting Social Engineering Attacks Using Natural Language Processing and Machine Learning,” *IEEE Access*, tập 10, tr. 113058–113071, 2022.
- [5] A. Sahingoz và cộng sự, “Machine Learning Based Phishing Detection from URLs,” *Expert Systems with Applications*, tập 117, tr. 345–357, 2019.
- [6] T. Fawcett, “An Introduction to ROC Analysis,” *Pattern Recognition Letters*, tập 27, số 8, tr. 861–874, 2006.
- [7] D. P. Kingma và J. Ba, “Adam: A Method for Stochastic Optimization,” *ICLR*, 2015.
- [8] I. Loshchilov và F. Hutter, “Decoupled Weight Decay Regularization,” *ICLR*, 2019.
- [9] C. Guo, G. Pleiss, Y. Sun và K. Q. Weinberger, “On Calibration of Modern Neural Networks,” *ICML*, 2017.
- [10] M. Ribeiro, S. Singh và C. Guestrin, “Why Should I Trust You? Explaining the Predictions of Any Classifier,” *KDD*, 2016.
- [11] A. Jacovi và Y. Goldberg, “Towards Faithfully Interpretable NLP Systems: How Should We Define and Evaluate Faithfulness?” *Proceedings of ACL*, 2020.

PHỤ LỤC

Phụ lục A. Lược đồ một mẫu dữ liệu ngữ nghĩa

```
{
  "text":      "Không      gửi      mã      OTP      cho      bất      kỳ      ai.",
  "candidate_action":      "DISCLOSE_SECRET",
  "requested":      "NO",
  "negated":      "YES",
  "quoted":      "NO",
  "reported":      "NO"
}
```

Trường kỹ thuật text là nội dung duy nhất mô hình đọc. Các trường còn lại là nhãn chuẩn dùng trong huấn luyện hoặc đánh giá. Khi tạo tập độc lập, chúng phải được tách khỏi FINAL_MODEL_INPUT.

Phụ lục B. Trạng thái hợp lệ của phép thử độc lập

MODEL_MODIFIED_AFTER_TEST_START	=	NO
THRESHOLD_TUNED_AFTER_TEST_START	=	NO
GOLD_OPENED_BEFORE_PREDICTION_FREEZE	=	NO
TEST_CASES_CHANGED_AFTER_TEST_START	=	NO
PREDICTIONS_FROZEN_BEFORE_GOLD	=	YES
FINAL_INDEPENDENT_TEST_VALID	=	YES

Phụ lục C. Dấu vân tay SHA256 của các thành phần nghiên cứu

Bảng PL1. SHA256 của các tệp dùng trong kết quả độc lập

Thành phần nghiên cứu	SHA256
Bản mô hình ngữ nghĩa đã lưu	Ae0420e7efbdb791b71907131c480e6fcb9d7cef9f1e4f6382cdc392eb66019
Bản mô hình mức độ rủi ro đã lưu	824B58d32366d746adc32b4350c73cad49054f538d365f6661da4036535c8328
FINAL_MODEL_INPUT	Bf28821ad7a00fdecdbf323a6fe4db26a74ecf21c7a4a63f9194f25682bc3d87
predictions_frozen.jsonl	67Aba49b6fb118d6b5c5ba4e335442a6bba7e5842706fe3477609bddf2c311cf
INTERNAL_GOLD	40807E46939000a487e5975b5b51942a11ffffb1a4ced3e66a5fa62b5fa7d2ef

Phụ lục D. Luồng sử dụng ứng dụng

1. 1. Người dùng dán văn bản, chọn ảnh chụp màn hình hoặc quét QR.

- 2.2. Ứng dụng chuẩn hóa đầu vào ở mức tối thiểu và gửi văn bản tới API trong mạng cục bộ.
- 3.3. API nạp bản mô hình đã lưu, mã hóa văn bản và trả về các thuộc tính ngữ nghĩa cùng mức độ rủi ro.
- 4.4. Ứng dụng hiển thị màu xanh, vàng hoặc đỏ, độ tin cậy và dữ liệu kỹ thuật.
- 5.5. Nếu bật chức năng sinh hướng dẫn, API gửi nội dung và mức độ đã có tới mô hình ngôn ngữ để tạo hướng xử lý; kết quả này không thay đổi nhãn mức độ rủi ro.

Phụ lục E. Gợi ý tái chạy

Người tái lập cần tạo môi trường theo tệp khai báo thư viện, tải đúng hai bản mô hình đã lưu, kiểm tra SHA256, khởi động API và cấu hình địa chỉ máy chủ trong ứng dụng Android. Muốn tái lập kết quả kiểm thử, phải dùng đúng FINAL_MODEL_INPUT, quy trình tiền xử lý, thứ tự mẫu và bản mô hình đã lưu; không được dùng INTERNAL_GOLD trong lúc suy luận.